

## 概率论与数理统计知识整理

注：这是作者在大二上学期的课，与线代合并成一门。概统部分仅用一个月学完，比较粗糙，很多内容没有讲，但是对非数学专业而言，这些知识已经够用。

### 第一章 概率论

#### 一、概率基本概念

- 1、基本事件：一次随机试验中的可能结果。
- 2、样本空间 $\Omega$ ：所有基本事件的集合。
- 3、事件：包含一个或多个基本事件的集合（或者空集）。事件是样本空间的子集。
- 4、频率： $N$ 次试验中事件  $A$  发生的次数为  $n$ ，则定义试验中  $A$  的频率  $F_N(A) = \frac{n}{N}$ 。

☆频率的性质

- (1) 非负性： $F_N(A) \geq 0$ 。（同时有  $F_N(A) \leq 1$ ）
- (2) 规范性： $F_N(\Omega) = \frac{N}{N} = 1$ 。
- (3) 可加性：若  $A, B \subseteq \Omega$  且二者不同时发生，则  $F_N(A+B) = F_N(A) + F_N(B)$ 。
- (4) 稳定性：必存在常数  $f$  使得  $\lim_{N \rightarrow \infty} F_N(A) = f$ 。
- 5、样本点：样本空间中的元素。其分布分为离散与连续。
  - (1) 离散：有限个或可列无限个。（可列：可以与自然数集合建立一一映射关系，例如全体偶数、全体有理数等）
  - (2) 连续：必要条件是无限且不可列。（如全体实数）
  - (3) 集合  $A$  的元素个数一般记为  $|A|$  或  $\text{card}(A)$ 。对事件而言相当于样本点个数。

#### 二、古典概型

- 1、古典概型的特征：样本空间 $\Omega$ 元素个数有限；所有基本事件发生概率相同（等可能性）。
- 2、古典概型中事件  $A$  的概率  $P(A) = \frac{|A|}{|\Omega|}$ 。
- 3、处理古典概型的常见方法
  - (1) 最直接的方法：将 $\Omega$ 与  $A$  的所有元素列出，数个数。（写集合、画树状图；交并关系复杂时使用文氏图）
  - (2) 排列组合，一切随缘；除此之外，暂时无可奉告。

#### 三、几何概型

- 1、基本特征：样本点无限多（一般用坐标系中的一个区域表示）；等可能性——若  $A, B \subseteq \Omega$  且  $V(A) = V(B)$ （见下面定义），则  $P(A) = P(B)$ 。
- 2、测度： $A$  的测度  $V(A)$  (Volume) 表示长度、面积、体积（包括更高维度的对应量）中与  $A$  维度相同的一个。例如，一维区间的测度为长度，二维区域的测度为面积，三维区域的测度为体积。
- 3、几何概型中事件  $A$  的概率  $P(A) = \frac{|A|}{|\Omega|} = \frac{V(A)}{V(\Omega)}$ 。
- 4、几何概型问题的关键：将纯文字的题干转化为图像。需要熟悉解析几何知识，

并且学会用不等式表示相应的区域。

5、子集簇：样本空间中所有事件的集合（事件本身是集合，子集簇就是集合的集合），也叫 $\sigma$ 域、事件域。记为  $F = \{A | A \subseteq \Omega\}$ 。

☆子集簇的性质：

- (1)  $\Omega \in F$  ；
- (2) 任意  $A \in F$  ，有  $\bar{A} = \Omega \setminus A \in F$  ；
- (3) 任意  $A_1, A_2, \dots \in F$  （有限个或可列无限个），有  $\bigcup_{i=1}^{\infty} A_i \in F$  。

#### 四、事件的运算

1、 $A \cap B$  或  $AB$ ：表示  $A$  与  $B$  同时发生的事件。

若  $A \cap B = \emptyset$ ，则说明二者不会同时发生，称  $A$  与  $B$  互斥。

2、 $A \subseteq B$ ： $A$  包含于  $B$ ，指  $A$  发生时  $B$  一定发生。 $A$  的样本点全部属于  $B$ 。（小的发生时大的一定发生，请勿记反）

若  $A \subseteq B$  且  $B \subseteq A$ ，则  $A = B$ 。

3、 $A \cup B$ ：表示  $A$  发生或  $B$  发生。（至少发生一个）

若  $A$  与  $B$  互斥，也记  $A \cup B$  为  $A+B$ 。

若  $A \cup B = \Omega$ ，且  $A \cap B = \emptyset$ ，说明  $A$  与  $B$  不同时发生，也不会都不发生（必有一个发生），称  $A$  与  $B$  互逆， $B$  是  $A$  的对立事件，记为  $B = \bar{A}$ 。

4、 $A \setminus B$ ： $\{x | x \in A \text{ 且 } x \notin B\}$ 。称为  $A$  与  $B$  的差事件。表示  $A$  发生但  $B$  不发生。

#### 5、事件运算律

- (1) 交换律： $A \cup B = B \cup A$ （或者  $AB = BA$ ）。
- (2) 结合律： $(A \cup B) \cup C = A \cup (B \cup C)$ （或  $(AB)C = A(BC)$ ）。
- (3) 分配律： $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$ 。
- (4) De Morgan 律： $\overline{A \cup B} = \bar{A} \cap \bar{B}$ ， $\overline{A \cap B} = \bar{A} \cup \bar{B}$ 。

e.g. 已知三个事件  $A, B, C$ 。

①  $A$  与  $B$  发生， $C$  不发生： $AB\bar{C}$  或  $AB \setminus C$  或  $AB \setminus (ABC)$ 。

② 三件事都发生： $ABC$ 。

③ 三件事至少发生一个： $A \cup B \cup C$  或  $\overline{\bar{A} \bar{B} \bar{C}}$ 。（算概率一般用后一个）

④ 三件事有且只有两个发生： $\bar{A} \cup \bar{B} \cup \bar{C}$  或  $\bar{A}BC + \bar{B}AC + \bar{C}AB$ 。

（注意  $\cup$  何时能写成  $+$ ，何时不能）

#### 五、概率公理化定义与概率空间

1、概率的三要素：样本空间  $\Omega$ ，子集簇  $F$ ， $F$  上的概率映射  $P(A)$ 。

#### 2、概率的性质

- (1) 非负性：任意  $A \in F$ ， $P(A) \geq 0$ 。
- (2) 规范性： $P(\Omega) = 1$ 。
- (3) 可列可加性：若  $A_1, A_2, \dots \in F$  且互斥，则  $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ 。

以上三条是最基本的性质；广义上，任何满足这三条性质的函数  $P(A)$  都可以叫做概率；称  $(\Omega, F, P)$  为概率空间。

(4)  $P(\emptyset) = 0$ 。

(5) 有限事件可加性：若  $A_1, A_2, \dots, A_n \in F$  且互斥， $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$ 。

(6) 互逆事件:  $P(A) + P(\bar{A}) = 1$ .

(7) 若  $B \subseteq A$ , 则  $P(A \setminus B) = P(A) - P(B)$ .

(8)  $P(A \cup B) = P(A) + P(B) - P(AB)$ .

(9) 一般情况下,  $P(A \setminus B) = P(A) - P(AB)$ .

结合公式 7, 若  $B \subseteq A$ , 则  $P(AB) = P(B)$ .

(10) 容斥原理 (多还少补定理)

$$P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) - \dots + (-1)^{n+1} P(A_1 A_2 \dots A_n).$$

① 内涵:  $n$  个集合并集元素个数的计算。把每个集合的元素加起来, 那么任意两个集合的交集都被算了两次, 所以要减掉; 减的过程中, 任意三个集合的交集都被减了两次, 所以要加回来; 以此类推.....

② 转化为不等式:  $P(\bigcup_{i=1}^n A_i) \leq \sum_{i=1}^n P(A_i)$ . (次可加性)

(11) 连续性:

若  $A_1 \supseteq A_2 \supseteq \dots$ , 记  $\lim_{n \rightarrow \infty} A_n = \bigcap_{i=1}^{\infty} A_i$ , 则  $\lim_{n \rightarrow \infty} P(A_n) = P(\lim_{n \rightarrow \infty} A_n)$ .

若  $A_1 \subseteq A_2 \subseteq \dots$ , 记  $\lim_{n \rightarrow \infty} A_n = \bigcup_{i=1}^{\infty} A_i$ , 则  $\lim_{n \rightarrow \infty} P(A_n) = P(\lim_{n \rightarrow \infty} A_n)$ .

(在事件序列层层包含时, 事件概率的极限等于事件极限的概率)

## 六、条件概率与两个重要概率公式

1、条件概率的定义: 在已知  $B$  发生的情况下  $A$  发生的概率被称为  $A$  关于  $B$  的条件概率, 记为  $P(A|B)$ 。

2、条件概率公式: 若  $P(B) \neq 0$ , 则  $P(A|B) = \frac{P(AB)}{P(B)}$ .

3、理解条件概率的意义: 条件概率  $P(A|B)$  与  $P(AB)$  是不一样的, 虽然看上去都是  $A$  与  $B$  同时发生。在考察交集事件  $AB$  时, 我们不默认  $A$  或者  $B$  一定会发生; 在考察条件概率  $P(A|B)$  时, 却是默认  $B$  一定会发生。这为认知者带来更多信息, 因此事件  $A$  的元素个数有所减少, 某些情况被排除, 从而  $P(A|B) \geq P(AB)$ 。我们对  $A$  的把握会更加准确。(这也说明“概率”本身依赖于我们知道的信息与理解句子的方式)

e.g. 家中有两个孩子。

(1) 求一男 (m) 一女 (f) 的概率:

$\Omega = \{(m,m), (m,f), (f,m), (f,f)\}$ ,  $A = \{(m,f), (f,m)\}$ , 故  $P(A) = 1/2$ .

(不添加任何已知信息, 默认什么都不知道)

(2) 已知有一个是女孩, 求一男一女的概率。

【法一】直接修改样本空间。  $\Omega' = \{(m,f), (f,m), (f,f)\}$ ,  $A = \{(m,f), (f,m)\}$ , 故  $P(A|\Omega') = 2/3$ . ( $\Omega$  中  $(m,m)$  被排除, 分母减小)

【法二】套用条件概率公式。  $P(A|\Omega') = P(A\Omega')/P(\Omega') = (1/2)/(3/4) = 2/3$ .

4、条件概率的改写:  $P(AB) = P(B)P(A|B) = P(A)P(B|A)$ .

推广到  $n$  个事件——多事件乘法公式:

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1}).$$

内涵:  $a_1 a_2 \dots a_n = a_1 \frac{a_1 a_2}{a_1} \frac{a_1 a_2 a_3}{a_1 a_2} \dots \frac{a_1 a_2 \dots a_n}{a_1 a_2 \dots a_{n-1}}$ . (只是形式上类似, 上述概率不一定

可以分解成乘积!)

#### 4、全概率公式

若事件  $A_1, A_2, \dots$  (有限或可列无限) 与  $B$  满足

(1)  $A_1, A_2, \dots$  互斥, 且概率均大于 0.

(2)  $B \subseteq \sum_{i=1}^{\infty} A_i$ .

则  $P(B) = \sum_{i=1}^{\infty} P(A_i)P(B|A_i)$ .

原理:  $B = B \cap (A_1 \cup A_2 \cup \dots) = (BA_1) \cup (BA_2) \cup \dots = \sum_{i=1}^{\infty} BA_i$ . (最初的等号是因为第二个条件)

\*简化形式:  $P(B) = P(A)P(B|A) + P(\bar{A})P(B|\bar{A})$ . ( $B$  一定包含于  $A \cup \bar{A}$ )

e.g. 决策问题: 排异使得当前选择胜算下降

已知  $n$  ( $n \geq 2$ ) 个袋子  $A_1, A_2, \dots, A_n$  中只有一个含有奖品。抽奖者选中  $A_1$ , 随后得知  $A_2, A_3, \dots, A_{n-1}$  都没有奖品。他获得一次机会, 可以决定是否换选  $A_n$ 。

设一开始猜  $A_1$  正好猜中为事件  $A$ , 最终获得奖品为事件  $B$ 。

对于事件  $A$ :  $P(A) = \frac{1}{n}$ ,  $P(\bar{A}) = 1 - \frac{1}{n}$ .

如果得知信息后决定换:  $P(B|A) = 0$ ,  $P(B|\bar{A}) = 1$ . (若  $A_1$  本身是对的, 换了就没有奖; 否则, 换了反而没有奖。)

如果不换:  $P(B|A) = 1$ ,  $P(B|\bar{A}) = 0$ . (理由与上面类似)

如果换,  $P(B) = P(A)P(B|A) + P(\bar{A})P(B|\bar{A}) = 1 - \frac{1}{n}$ .

如果不换,  $P(B) = P(A)P(B|A) + P(\bar{A})P(B|\bar{A}) = \frac{1}{n}$ .

只要  $n \geq 2$ , 则换的胜算远大于不换。

【理解 1】最开始, 奖品在每个袋子中的概率都是  $1/n$ ; 得知信息后, 后  $n-1$  个袋子的可能性全部集中到  $A_n$ , 因此选  $A_n$  胜算更大; 不能认为知道信息之后中奖的概率是  $1/2$ , 因为选  $A_1$  在先。只有先知道信息再选  $A_1$  或  $A_n$  才是  $1/2$  的概率。

【理解 2】对于事件  $A$ , 猜不中的可能性比猜得中要大。这时, 只剩两个选项, 猜  $A_1$  猜不中就等价于选  $A_n$  是对的, 因此  $A_n$  对的可能性比  $A_1$  大, 所以当然会换成  $A_n$ 。同样, 在先排除  $A_2, A_3, \dots, A_{n-1}$  后再选  $A_1$  或  $A_n$ , 这两个选项才是平等的, 这和一开始就只给两个选项是一样的。

e.g. 抽签问题:  $n$  人抽  $n$  张签, 只有一张有奖。

(1) 不知道任何信息时, 得奖概率和抽签顺序无关。因为第  $k$  人得奖的概率为  $P(\bar{A}_1 \dots \bar{A}_{k-1} A_k) = P(\bar{A}_1)P(\bar{A}_2 | \bar{A}_1)P(\bar{A}_3 | \bar{A}_1 \bar{A}_2) \dots P(A_k | \bar{A}_1 \dots \bar{A}_{k-1})$   
 $= \frac{n-1}{n} \frac{n-2}{n-1} \frac{n-3}{n-2} \dots \frac{1}{n-k+1} = \frac{1}{n}$ , 与  $k$  无关。

(2) 在已经知道前面  $k-1$  人未得奖时, 第  $k$  人得奖的概率为  $P(A_k | \bar{A}_1 \dots \bar{A}_{k-1}) = \frac{1}{n-k+1}$ . 这时越后抽奖越有利。

5、贝叶斯公式：在全概率公式的两个条件下，有

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(B)} = \frac{P(A_i)P(B|A_i)}{\sum_{k=1}^{\infty} P(A_k)P(B|A_k)}.$$

(1) 内涵：全概率公式是由各个因素贡献之和求出结果，贝叶斯公式是由结果回推各个因素的贡献。（二者等号左边待求的事件不一样）

(2) 由贝叶斯公式得出条件概率的关系： $P(A)P(B|A) = P(B)P(A|B)$ .（事实上这是显然的，两者都等于  $P(AB)$ ）

6、事件的独立性

(1) 统计独立：若两个事件是否发生不会互相影响，则称二者（统计）独立。

(2) 独立事件 A、B 的性质

①  $P(A|B) = P(A)$ .（B 发不发生，不影响 A 的概率）

②  $P(AB) = P(A)P(B)$ .

以上两条是事件独立的充要条件，可用于判断两个事件是否独立。

③任何事件均与  $\emptyset$  独立，也必然与样本空间  $\Omega$  独立。

(3) 多个事件的独立： $n$  个事件  $A_1, A_2, \dots, A_n$ ，等价于对一切可能组合  $1 \leq i < j < k < \dots < n$ ，有

$$\left\{ \begin{array}{l} P(A_i A_j) = P(A_i)P(A_j) \\ P(A_i A_j A_k) = P(A_i)P(A_j)P(A_k) \\ \dots \\ P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots P(A_n) \end{array} \right.$$

(4) 非独立的一个充分条件：若事件 A、B 互斥，且  $P(A)P(B) \neq 0$ ，则 A、B 不独立。

【理解 1】代数上， $P(AB) = 0 \neq P(A)P(B)$ ，因此不满足独立的条件。

【理解 2】本质意义上，两个互斥事件，一个发生必然导致另一个不发生，这便是两件事之间的影响；如果两件事发生的概率都不是 0，那么二者就有互相影响的可能性，所以不独立。

(5) 若 A 与 B 独立，则 A 与  $\bar{B}$ ， $\bar{A}$  与 B， $\bar{A}$  与  $\bar{B}$  也独立。

推广的结论：以上四组中，有任意一组独立，则另外三组也独立。

七、一维随机变量

(一) 一维离散型随机变量

1、离散型随机变量的定义：取值集合的元素个数是有限个或可列无限个。

2、离散型随机变量  $\xi$  的分布常用概率分布表来表示，第一行为  $\xi$  的可能取值，第二行为各个取值对应的概率值。

☆☆☆概率分布表最基本的特征：归一性。所有概率值之和为 1，这是求解参数时几乎不得不使用但是很容易被忘记的一个结论！

3、Bernoulli 试验：多次重复、独立的试验，每次试验只有两种互斥的结果。例如抛硬币。若干次 Bernoulli 试验对应的模型称为 Bernoulli 概型。0-1 分布、二项分布、几何分布均与 Bernoulli 试验有关。

4、常见的一维离散型分布

(1) 0-1 分布：一次 Bernoulli 试验中，记成功为  $\xi = 1$ ，失败为  $\xi = 0$ 。一般记成功的概率为  $p$ ，失败的概率为  $q = 1 - p$ 。

(2) 二项分布: Bernoulli 试验总次数为  $n$ , 记其中成功的次数为  $\xi$ , 则  $\xi$  满足二项分布。对于  $0 \leq k \leq n$ , 有  $P(\xi = k) = C_n^k p^k q^{n-k}$ .  $p$  和  $q$  的定义同上。这一关系记为  $\xi \sim B(n, p)$ , 而  $P(\xi = k)$  记为  $b(k; n, p)$ .

(3) 几何分布: Bernoulli 试验总次数为  $n$ , 记第一次成功时的试验次数为  $\xi$ , 则  $\xi$  满足几何分布。

① 对于  $1 \leq k \leq n$ , 有  $P(\xi = k) = pq^{k-1}$ .

② 无记忆性: 若从第一次试验开始  $\xi$  服从几何分布, 则对于任意正整数  $m$ , 若前  $m$  次试验均失败, 则从第  $m$  次试验开始计算, 第一次成功时的试验次数  $\eta = \xi - m$  也服从几何分布。

$$P(\eta = k | \text{前} m \text{次失败}) = \frac{P(\eta = k \text{ 且 前} m \text{次失败})}{P(\text{前} m \text{次失败})} = \frac{pq^{m+k-1}}{q^m} = pq^{k-1} = P(\xi = k).$$

(实例: 多次抽奖, 前面抽不到不会使后面中奖的概率变大。)

(4) Poisson 分布

① 定义: 对于取值集合为自然数集的随机变量  $\xi$ , 若  $P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ , 则称  $\xi$  服从

Poisson 分布, 记作  $\xi \sim P(\lambda)$ .

② Poisson 定理: 在某些特殊的 Bernoulli 试验中, 每次成功的概率与次数  $n$  有关,

记作  $p_n$ ; 若  $\lim_{n \rightarrow \infty} np_n = \lambda$ , 则  $\lim_{n \rightarrow \infty} P(\xi = k) = \lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$ . (二项分布在试验次数充分大时近似为 Poisson 分布)

③ \*满足以下条件的变量服从 Poisson 分布 (也是 Poisson 分布的性质):

(i) 平稳性: 落在区间  $[t_0, t_0 + \Delta t]$  内的次数与  $\Delta t$  有关, 与  $t_0$  无关。

(ii) 独立增量性: 落在区间  $[t_0, t_0 + \Delta t]$  内的次数与  $t_0$  之前的事件无关。

(iii) 普通性: 在任意无限小区间内至多只有一次呼叫 (不会出现奇点)。

(二) 一维连续型随机变量

1、分布函数

(1) 对于随机变量  $\xi$ , 定义其分布函数  $F_\xi(x) = P(\xi \leq x)$ . (实质: 从负无穷大开始的概率值的累积。这个函数对离散和连续变量都可以定义。)

(2) 分布函数的性质

注: 离散变量的分布函数多数是不连续的 (阶梯状), 要注意书写函数解析式时分段点的函数值。与此同时, 分布函数都是定义在  $(-\infty, +\infty)$  上的, 在  $\xi$  所能取的最小以下, 函数值为 0; 在  $\xi$  所能取的最大值以上, 函数值为 1。

$$\textcircled{1} P(\xi < a) = \lim_{b \rightarrow a^-} P(\xi \leq b) = F(a^-).$$

$$\textcircled{2} P(\xi = a) = P(\xi \leq a) - P(\xi < a) = F(a) - F(a^-).$$

$$\textcircled{3} P(\xi > a) = 1 - P(\xi \leq a) = 1 - F(a).$$

$$\textcircled{4} P(a < \xi < b) = P(\xi < b) - P(\xi \leq a) = F(b^-) - F(a).$$

⑤ 单调性: 若  $a < b$ , 则  $F(a) \leq F(b)$ .

⑥ 规范性:  $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1$ . ( $x \leq -\infty$  不可能发生,  $x \leq +\infty$  一定发生)

☆☆☆这是求解参数时几乎不得不使用但是很容易被忘记的一个结论!

⑦ 右连续性:  $F(x^+) = F(x)$ .

对比: 若定义  $G_\xi(x) = P(\xi < x)$ , 则它应当是左连续的。

## 2、概率密度函数（仅对连续型变量定义）

（1）连续变量不存在点概率：连续变量相当于有无限不可列个取值。因此，如果要计算  $P(\xi = a)$ ，它总是等于有限的事件样本除以无限的基本事件个数，总是趋于 0（具体体现为分布函数的连续性，即  $P(\xi = a) = F(a) - F(a^-) = 0$ ）。在连续变量的讨论中，概率为 0 不一定是不可能事件，概率为 1 不一定是必然事件。因此，不能用概率为 0 或者 1 来定义不可能与必然。

\*典型例子：在一条线段 AB 上等可能地取点。若 C 在线段 AB 上，可以计算点落在 AC 段的概率为  $\frac{|AC|}{|AB|}$ （是几何概型），但是由于 C 点本身没有长度，因此

这个点落在 C 上的概率为  $\frac{0}{|AB|} = 0$ ，落在 C 点以外位置的概率为  $\frac{|AC| + |CB|}{|AB|} = 1$ 。

但是这个点显然不是不可能落在 C 点，也不是必定落在 C 以外的位置。

**结论：连续型随机变量不能够定义取值在某个点的概率，只能定义在一段区间内取值的概率。为了体现出依赖于区间长度的性质，定义单位区间长度上的概率，即为概率密度。**

（2）概率密度的规范定义：若随机变量  $\xi$  可以取得在某个区间内的所有实数，并且存在非负可积函数  $\varphi(x)$  使得  $F_{\xi}(x) = \int_{-\infty}^x \varphi(t) dt$ ，则称  $\varphi(x)$  为  $\xi$  的概率密度函数。

①离散变量的分布函数总是存在不可导、不连续点，因此不能定义概率密度；连续变量与离散变量的区别就好像刚体与质点组的区别，质点的质量全部集中在一个点，是不可能对它谈论密度的。

②只有存在概率密度的函数才是连续性随机变量，这是它的一个判定依据。

（3）密度函数的性质

①  $P(a < \xi \leq b) = F(b) - F(a) = \int_a^b \varphi(x) dx$ .（质量 = 密度 × 体积，概率 = 概率密度 × 区间长度。如果不是均匀分布，上述式子改写成积分。）

②连续性： $P(\xi = a) = F(a) - F(a^-) = \lim_{\varepsilon \rightarrow 0^+} \int_{a-\varepsilon}^a \varphi(x) dx = 0$ .

③对一般点（不考虑可能出现的端点）， $\varphi(x) = \frac{dF(x)}{dx}$ .

④非负性： $\varphi(x) \geq 0$ .

⑤归一性： $\int_{-\infty}^{+\infty} \varphi(x) dx = 1$ .

☆☆☆概率密度最基本的特征：归一性。这是求解参数时几乎不得使用但是很容易被忘记的一个结论！

（任意满足  $\int_{-\infty}^{+\infty} \varphi(x) dx = 1$  的非负函数  $\varphi(x)$  均可视为某个变量的密度函数。）

## 3、常见的连续分布

（1）区间  $[a, b]$  上的均匀分布  $U[a, b]$ :

$$\varphi(x) = \begin{cases} \frac{1}{b-a}, & a \leq x < b, \\ 0, & \text{其他.} \end{cases} \quad F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$$

（只在区间  $[a, b]$  上有分布，各个地方的取值可能性一样。相当于前述的线段取点对应的几何概型。）

(2) 指数分布  $E(\lambda)$ :

$$\varphi(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases} \quad F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x \leq 0. \end{cases}$$

指数分布同样有无记忆性:  $P(\xi > s+t | \xi > s) = P(\xi > t)$ .

(3) ☆正态分布  $N(\mu, \sigma^2)$ : 注意括号里面第二个数是  $\sigma^2$  而不是  $\sigma$ 。 ( $\sigma > 0$ )

$$\varphi(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}. \quad F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt.$$

①熟记积分:  $\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$ . (可以用二重积分或者  $\Gamma$  函数证明)

②正态分布的标准化: 若  $\xi \sim N(\mu, \sigma^2)$ , 则  $\frac{\xi - \mu}{\sigma} \sim N(0, 1)$ . 称  $N(0, 1)$  为标准正态分布, 所有正态分布都可以归结为标准正态分布。

③若  $\xi \sim N(\mu, \sigma^2)$ , 则  $a\xi + b \sim N(a\mu + b, a^2\sigma^2)$

④正态分布的分布函数一般记作  $\Phi_{\xi}(x)$ , 标准正态分布记为  $\Phi_0(x)$ 。有以下性质:

$$(i) \quad \Phi_{\xi}(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt \stackrel{u=\frac{t-\mu}{\sigma}}{=} \int_{-\infty}^{\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du = \Phi_0(u) = \Phi_0\left(\frac{x-\mu}{\sigma}\right).$$

$$(ii) \quad \Phi_0(x) + \Phi_0(-x) = 1.$$

$$(iii) \quad P(a < \xi \leq b) = \Phi_{\xi}(b) - \Phi_{\xi}(a) = \Phi_0\left(\frac{b-\mu}{\sigma}\right) - \Phi_0\left(\frac{a-\mu}{\sigma}\right).$$

(iv) 统计学  $3\sigma$  原则:  $P(|\xi - \mu| < 3\sigma) = \Phi_0(3) - \Phi_0(-3) = 0.9973$ . 正态分布的变量几乎全都落在区间  $(\mu - 3\sigma, \mu + 3\sigma)$  中。可以用于检验  $\mu$  和  $\sigma$  测量值是否准确。

## 八、二维随机变量

1、高维随机变量的定义: 在样本空间  $\Omega$  中定义  $n$  个一维随机变量  $\xi_1, \xi_2, \dots, \xi_n$ , 它们可能独立也可能有牵连。它们构成的  $n$  维向量  $(\xi_1, \xi_2, \dots, \xi_n)$  称为  $n$  维随机变量。

2、二维随机变量  $(\xi, \eta)$  联合分布的表示

(1) 离散型随机变量: 联合分布表。

(2) 离散/连续型: 联合分布函数。  $F_{\xi, \eta}(x, y) = P(\xi \leq x, \eta \leq y)$ .

①  $P(a_1 \leq \xi \leq b_1, a_2 \leq \eta \leq b_2) = F(a_1, a_2) + F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2)$ . ( $(\xi, \eta)$  落在矩形区域的概率是右斜对角线减去左斜对角线)

推论:  $F(a_1, a_2) + F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2) \geq 0$ . ( $a_1 < b_1, a_2 < b_2$ )

②值域:  $0 \leq F_{\xi, \eta}(x, y) \leq 1$ .

③  $F_{\xi, \eta}(x, y)$  对  $x$  与  $y$  均单调递增且右连续。

④任意实数  $x$  与  $y$ ,  $F(x, -\infty) = F(-\infty, y) = 0$ ,  $F(+\infty, +\infty) = 1$ .

☆☆☆这是求解参数时几乎不得不使用但是很容易被忘记的结论!

(3) 连续型: 联合密度函数。(二维变量落在一个点处的概率同样趋于 0, 只能定义落在一个二维区域内的概率。为了体现不依赖于区域面积的性质, 定义单位面积上的概率, 即为二维概率密度。)

①定义: 若存在非负可积二元函数  $\varphi(x, y)$  使得  $F_{\xi, \eta}(x, y) = \int_{-\infty}^x \int_{-\infty}^y \varphi(s, t) ds dt$ , 则称  $\varphi(x, y)$  为  $(\xi, \eta)$  的联合概率密度函数。(这也是判定二维连续变量的一个依据)



$$\textcircled{2} \frac{\partial F}{\partial x} = \int_{-\infty}^y \varphi(x, t) dt, \quad \frac{\partial F}{\partial y} = \int_{-\infty}^x \varphi(s, y) ds; \quad \frac{\partial^2 F}{\partial x \partial y} = \varphi(x, y).$$

### 3、边缘分布

(1) 定义：由二维（或更高维）联合分布生成的一维变量的分布律。

(2) 离散型 $(\xi, \eta)$ 的边缘分布： $\xi, \eta$ 的取值均是有限个或可列无限个。

$$P(\xi = x_i) = \sum_{j=1}^{\infty} P(\xi = x_i, \eta = y_j) = \sum_{j=1}^{\infty} p_{ij} \equiv p_{i*}. \quad (i = 1, 2, \dots)$$

$$P(\eta = y_j) = \sum_{i=1}^{\infty} P(\xi = x_i, \eta = y_j) = \sum_{i=1}^{\infty} p_{ij} \equiv p_{*j}. \quad (j = 1, 2, \dots)$$

(3) 连续型 $(\xi, \eta)$ 的边缘分布：

$$\varphi_{\xi}(x) = \int_{-\infty}^{+\infty} \varphi(x, t) dt = \left. \frac{\partial F}{\partial x} \right|_{y=-\infty}^{y=+\infty}, \quad \varphi_{\eta}(y) = \int_{-\infty}^{+\infty} \varphi(s, y) ds = \left. \frac{\partial F}{\partial y} \right|_{x=-\infty}^{x=+\infty}.$$

(4) 用分布函数得到边缘分布（离散/连续）：

$$F_{\xi}(x) = F_{\xi, \eta}(x, +\infty), \quad F_{\eta}(y) = F_{\xi, \eta}(+\infty, y).$$

(5) 边缘分布推导过程的实质：用全概率公式消元。

### 4、常见二维连续分布

(1) 二维区域  $D$ （面积为  $S_D$ ）上的均匀分布：
$$\varphi(x, y) = \begin{cases} \frac{1}{S_D}, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

(2) 二维正态分布（函数解析式不必记住）： $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$

$$\varphi(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]}.$$

①边缘分布：不论 $\rho$ 取值如何，均有 $\xi \sim N(\mu_1, \sigma_1^2)$ ， $\eta \sim N(\mu_2, \sigma_2^2)$ 。

②对于  $n$  维随机变量  $\xi = \begin{pmatrix} \xi_1 \\ \dots \\ \xi_n \end{pmatrix}$ ，设其对应自变量  $x = \begin{pmatrix} x_1 \\ \dots \\ x_n \end{pmatrix}$ ， $\mu = \begin{pmatrix} \mu_1 \\ \dots \\ \mu_n \end{pmatrix}$ ，则有  $n$  维

$$\text{正态分布函数 } \varphi(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} \sqrt{|\mathbf{B}|}} e^{-\frac{1}{2}(\mathbf{x}-\mu)^T \mathbf{B}^{-1}(\mathbf{x}-\mu)}.$$

$$\text{其中协方差矩阵 } \mathbf{B} = \begin{pmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 & \dots & \rho_{1n}\sigma_1\sigma_n \\ \rho_{12}\sigma_1\sigma_2 & \sigma_2^2 & & \\ \dots & & \dots & \\ \rho_{1n}\sigma_1\sigma_n & & & \sigma_n^2 \end{pmatrix}.$$

③若 $\xi_i \sim N(\mu_i, \sigma_i^2) (1 \leq i \leq n)$ ，则 $\sum_{i=1}^n a_i \xi_i \sim N(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2)$ 。

### 九、随机变量的独立性与相关性

1、 $\xi$ 与 $\eta$ 统计独立 $\Leftrightarrow F_{\xi, \eta}(x, y) = F_{\xi}(x)F_{\eta}(y)$ 。

如果是连续变量：等价于 $\varphi_{\xi, \eta}(x, y) = \varphi_{\xi}(x)\varphi_{\eta}(y)$ 。

如果是离散变量：等价于 $p_{ij} = p_{i*}p_{*j}$ 。

2、二维正态分布  $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$  中,  $\xi$  与  $\eta$  统计独立  $\Leftrightarrow \rho = 0$ .

### 十、随机变量函数

1、已知  $\xi$  是随机变量, 则  $\xi$  的函数  $\eta = f(\xi)$  也是随机变量。

2、离散随机变量函数的概率分布: 将  $\eta$  的值和  $\xi$  的值对应起来, 得到各个事件的概率。

3、连续性随机变量函数的概率分布:  $\varphi_\eta(z) = \varphi_\xi(x(z)) \left| \frac{dx}{dz} \right|$ .

【理解 1】若  $f(\xi)$  随  $\xi$  单调递增, 则  $\eta \leq z \Leftrightarrow \xi \leq x(z)$ . 故  $F_\eta(z) = F_\xi(x(z))$ .

从而  $\varphi_\eta(z) = \frac{dF_\eta(z)}{dz} = \frac{dF_\xi(x(z))}{dz} = \frac{dF_\xi(x(z))}{dx} \frac{dx}{dz} = \varphi_\xi(x(z)) \left| \frac{dx}{dz} \right|$ . (复合函数求导)

若  $f(\xi)$  随  $\xi$  单调递减, 则  $\eta \leq z \Leftrightarrow \xi \geq x(z)$ . 故  $F_\eta(z) = 1 - F_\xi(x(z))$ .

从而  $\varphi_\eta(z) = -\frac{dF_\eta(z)}{dz} = -\frac{dF_\xi(x(z))}{dz} = -\frac{dF_\xi(x(z))}{dx} \frac{dx}{dz} = \varphi_\xi(x(z)) \left| \frac{dx}{dz} \right|$ .

【理解 2】当  $\xi$  落在小区间  $(x, x + \Delta x)$  时,  $\eta$  落在一个对应的小区间  $(z, z + \Delta z)$ , 这两个事件等价, 从而概率相同:  $\varphi_\eta(z) \Delta z = \varphi_\xi(x) \Delta x$ . 因此

$$\varphi_\eta(z) = \varphi_\xi(x(z)) \frac{\Delta x}{\Delta z} = \varphi_\xi(x(z)) \left| \frac{dx}{dz} \right|.$$

(1) 若  $\eta = a\xi + b$ , 则  $\varphi_\eta(x) = \frac{1}{|a|} \varphi_\xi\left(\frac{x-b}{a}\right)$ .

(2) 若二维随机变量  $(\xi, \eta)$  的联合概率密度函数为  $\varphi(x, y)$ ,  $\zeta = \xi + \eta$ , 则

$$F_\zeta(z) = P(\xi + \eta \leq z) = \iint_{x+y \leq z} \varphi(x, y) dx dy = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} \varphi(x, y) dy$$

$$= \int_{-\infty}^{+\infty} dx \int_{-\infty}^z \varphi(x, t-x) dt = \int_{-\infty}^z dt \int_{-\infty}^{+\infty} \varphi(x, t-x) dx.$$

$$\text{因此 } \varphi_\zeta(z) = \frac{d}{dz} \int_{-\infty}^z dt \int_{-\infty}^{+\infty} \varphi(x, t-x) dx = \int_{-\infty}^{+\infty} \varphi(x, z-x) dx.$$

(3) 最值函数: 若  $\xi$  与  $\eta$  统计独立,  $\zeta = \max\{\xi, \eta\}$ ,  $\kappa = \min\{\xi, \eta\}$ , 则

$$F_\zeta(z) = P(\xi \leq z, \eta \leq z) = F_\xi(z) F_\eta(z).$$

$$F_\kappa(z) = 1 - P(\xi > z, \eta > z) = 1 - [1 - F_\xi(z)][1 - F_\eta(z)].$$

然后可以求得相应的密度函数。

### 十一、随机变量的数字特征

1、数学期望的概念: 数学期望  $E\xi$  是随机变量  $\xi$  在概率意义下的均值, 即多次试验中,  $\xi$  各个取值的频率完全和概率一致时对应的平均值。

2、数学期望的计算

(1) 单个离散变量:  $E\xi = \sum_{i=1}^{\infty} x_i p_i$ . (有限/可列无限; 要求这个级数绝对收敛,

否则期望不存在)

(2) 单个连续变量:  $E\xi = \int_{-\infty}^{+\infty} x \varphi(x) dx$ . (要求此积分绝对收敛, 否则期望不存在)

(3) 离散的随机变量函数:  $Ef(\xi) = \sum_{i=1}^{\infty} f(x_i) p_i$ .

(4) 连续的随机变量函数:  $Ef(\xi) = \int_{-\infty}^{+\infty} f(x) \varphi(x) dx$ .

(5) 数学期望的性质

①若  $\xi = c$  为常数, 则  $E\xi = c$ .

②线性:  $E \sum_{i=1}^n c_i \xi_i = \sum_{i=1}^n c_i E\xi_i$ . ( $E(a\xi + b) = aE\xi + b$ .)

③若  $\xi_1, \xi_2, \dots, \xi_n$  统计独立 且期望均存在, 则  $E \prod_{i=1}^n \xi_i = \prod_{i=1}^n E\xi_i$ .

④  $E(\xi - E\xi) = E\xi - E\xi = 0$ .

3、方差的概念: 方差  $D\xi$  (有时也写成  $\text{Var}\xi$ ,  $V\xi$ ) 是随机变量  $\xi$  离散程度的体现。平方是为了让分布在平均值左边和右边的值对方差都是正的贡献, 而不会抵消。

4、方差的计算

(1) 定义式:  $D\xi = E(\xi - E\xi)^2$ . (可以看出  $D\xi \geq 0$ . 定义  $\sqrt{D\xi}$  为标准差。)

(2) 与数学期望的关系 (常用):  $D\xi = E(\xi^2) - (E\xi)^2$ . (平方的平均值未必等于平均值的平方, 并且是  $E(\xi^2) \geq (E\xi)^2$ )

(3) 离散变量:  $D\xi = \sum_{i=1}^{\infty} (x_i - E\xi)^2 p_i = \sum_{i=1}^{\infty} x_i^2 p_i - (\sum_{i=1}^{\infty} x_i p_i)^2$ .

(4) 连续变量:  $D\xi = \int_{-\infty}^{+\infty} (x - E\xi)^2 \varphi(x) dx = \int_{-\infty}^{+\infty} x^2 \varphi(x) dx - \left( \int_{-\infty}^{+\infty} x \varphi(x) dx \right)^2$ .

(5) 方差的性质

①若  $\xi = c$  为常数, 则  $D\xi = 0$ .

②  $D(a\xi + b) = a^2 D\xi$ .

③若  $\xi_1, \xi_2, \dots, \xi_n$  统计独立 且方差均存在, 则  $D \sum_{i=1}^n c_i \xi_i = \sum_{i=1}^n c_i^2 D\xi_i$ .

④若  $\xi_1, \xi_2, \dots, \xi_n$  统计独立 且服从相同分布 (如各次 Bernoulli 试验的结果), 则有

$$E\bar{\xi} = E\left(\frac{1}{n} \sum_{i=1}^n \xi_i\right) = E\xi_1; \quad D\bar{\xi} = D\left(\frac{1}{n} \sum_{i=1}^n \xi_i\right) = \frac{1}{n} D\xi_1.$$

5、常见离散分布的期望与方差

分布律	概率公式	期望	方差
0-1 分布	$P(\xi = 1) = p$ $P(\xi = 0) = q$	$p$	$pq$
二项分布	$P(\xi = k) = C_n^k p^k q^{n-k}$	$np$	$npq$
Poisson 分布	$P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda}$	$\lambda$	$\lambda$
几何分布	$P(\xi = k) = pq^{k-1}$	$\frac{1}{p}$	$\frac{q}{p^2}$

## 6、常见连续分布的期望与方差

分布律	期望	方差
均匀分布 $U[a, b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $E(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布 $N(\mu, \sigma^2)$	$\mu$	$\sigma^2$

## 7、协方差与相关系数

(1) 协方差:  $\text{Cov}(\xi, \eta) = E[(\xi - E\xi)(\eta - E\eta)]$ . (注意: 如果  $\xi, \eta$  不独立, 它就不能拆成  $E(\xi - E\xi) \cdot E(\eta - E\eta)$ , 因此它不一定是 0)

(2) 协方差矩阵:  $\xi_1, \xi_2, \dots, \xi_n$  的协方差矩阵为  $(\text{Cov}(\xi_i, \xi_j))_{n \times n}$ .

(3) 协方差的两个计算式:

$$\textcircled{1} \text{Cov}(\xi, \eta) = E(\xi\eta) - E\xi E\eta.$$

$$\textcircled{2} \text{Cov}(a\xi, b\eta) = ab\text{Cov}(\xi, \eta).$$

$$(4) \text{ 相关系数: } \rho_{\xi, \eta} = \frac{\text{Cov}(\xi, \eta)}{\sqrt{D\xi \cdot D\eta}}.$$

$\textcircled{1}$  取值范围:  $-1 \leq \rho_{\xi, \eta} \leq 1$ .

$\textcircled{2}$  若  $\rho_{\xi, \eta} = 0$ , 则称  $\xi, \eta$  不相关。

$\textcircled{3}$  独立是不相关的充分不必要条件。

这是因为: 由  $\varphi_{\xi, \eta}(x, y) = \varphi_{\xi}(x)\varphi_{\eta}(y)$ . 可以得出

$$E(\xi\eta) = \iint_{\mathbf{R}^2} xy\varphi_{\xi, \eta}(x, y)dxdy = \int_{-\infty}^{+\infty} x\varphi_{\xi}(x)dx \int_{-\infty}^{+\infty} y\varphi_{\eta}(y)dy = E\xi E\eta,$$

但是已知  $\iint_{\mathbf{R}^2} xy\varphi_{\xi, \eta}(x, y)dxdy = \int_{-\infty}^{+\infty} x\varphi_{\xi}(x)dx \int_{-\infty}^{+\infty} y\varphi_{\eta}(y)dy = \iint_{\mathbf{R}^2} xy\varphi_{\xi}(x)\varphi_{\eta}(y)dxdy$  并不能直接得到  $\varphi_{\xi, \eta}(x, y) = \varphi_{\xi}(x)\varphi_{\eta}(y)$ . (两个期望可能只是恰好相等, 就好像由

$\int_a^b f(x)dx = \int_a^b g(x)dx$  并不能得到  $f(x) = g(x)$ 。充分不必要性的来由就是: 积分只能体现一个区域上的总体性质而不能体现每个点的性质, 而每个点明确之后却可以得到总体性质)

$\textcircled{4}$  如果两个随机变量服从正态分布, 那么相关与独立是等价的。

原因:  $\text{Cov}(\xi, \eta) = \rho\sigma_1\sigma_2$ ,  $\rho_{\xi, \eta} = \rho$ , 故  $\xi, \eta$  独立  $\Leftrightarrow \rho = 0 \Leftrightarrow \rho_{\xi, \eta} = 0 \Leftrightarrow \xi, \eta$  不相关。

8、分位数: 若  $F(x_{\alpha}) = P(\xi \leq x_{\alpha}) = \alpha$ , 则称  $x_{\alpha}$  为随机变量的下侧  $\alpha$  分位数。同理可以定义上侧  $\alpha$  分位数  $x'_{\alpha}$ :  $1 - F(x'_{\alpha}) = P(\xi \geq x'_{\alpha}) = \alpha$ . 当  $\alpha = 0.5$  时, 对应的分位数称为中位数。

## 十二、大数定理与中心极限定理 (不是重点)

1、Bernoulli 大数定律: 对于  $n$  次满足 0-1 分布的 Bernoulli 试验  $\{\xi_1, \xi_2, \dots, \xi_n\}$ , 若每次成功概率为  $p$ , 则任意  $\varepsilon > 0$ ,  $\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n \xi_i - p\right| \leq \varepsilon\right) = 1$ . 平均值必然趋向于数学期望。

2、大数定律的一般形式：已知随机变量序列  $\{\xi_n\}$ ，若存在实数  $\xi$ ，使得任意  $\varepsilon > 0$ ， $\lim_{n \rightarrow \infty} P(|\xi_n - \xi| \leq \varepsilon) = 1$ ，则称  $\{\xi_n\}$  服从大数定律，也称  $\{\xi_n\}$  依概率收敛于  $\xi$ ，记作  $\{\xi_n\} \xrightarrow{P} \xi$ 。

3、切比雪夫不等式：若随机变量  $\xi$  存在方差，则对任意  $\varepsilon > 0$ ， $P(|\xi - E\xi| \geq \varepsilon) \leq \frac{D\xi}{\varepsilon^2}$ 。

意义：说明随机变量大部分还是分布在期望附近。由此可以将正态分布的  $3\sigma$  原则推广至任意分布——随机变量  $\xi$  大部分落在区间  $(E\xi - 3\sqrt{D\xi}, E\xi + 3\sqrt{D\xi})$  中。

4、大数定律的三种表述

设  $\{\xi_n\}$  是彼此独立的随机变量序列，期望都存在。如果：

(1) (切比雪夫) 存在公共的实数  $L$  使得  $D\xi_i \leq L$ ；

(2) (马可夫)  $\lim_{n \rightarrow \infty} \frac{1}{n^2} \sum_{i=1}^n D\xi_i = 0$ ；

(3) (辛钦)  $\{\xi_n\}$  服从同分布。

三个条件满足任意一个，则  $\frac{1}{n} \sum_{i=1}^n \xi_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n E\xi_i$ 。

①以上三个条件的设计都是基于以下理由：

$$D\left(\frac{1}{n} \sum_{i=1}^n \xi_i - \frac{1}{n} \sum_{i=1}^n E\xi_i\right) = \frac{1}{n^2} \sum_{i=1}^n D\xi_i \Rightarrow P\left(\left|\frac{1}{n} \sum_{i=1}^n \xi_i - \frac{1}{n} \sum_{i=1}^n E\xi_i\right| \geq \varepsilon\right) \leq \frac{1}{n^2 \varepsilon^2} \sum_{i=1}^n D\xi_i.$$

三个条件满足任意一个，则  $\lim_{n \rightarrow \infty} \frac{1}{n^2 \varepsilon^2} \sum_{i=1}^n D\xi_i = 0$ 。由夹逼性可以得到结论。

②意义：数据量很大时，频率终将趋向概率；可以用频率逼近从而求得概率，也可以用概率来解释频率。概率理论是有实际价值的，而不是理想化的空中楼阁。

5、中心极限定理的几种表述

(1) (Laplace) 对于  $n$  次满足 0-1 分布的 Bernoulli 试验  $\{\xi_1, \xi_2, \dots, \xi_n\}$ ，成功次数  $S_n = \sum_{i=1}^n \xi_i$ ，则在  $n$  充分大时， $\frac{S_n - np}{\sqrt{np(1-p)}}$  近似服从标准正态分布  $N(0,1)$ 。数学

$$\text{形式为 } \lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt.$$

(2) (定义形式) 已知随机变量序列  $\{\xi_n\}$ ，若存在数列  $\{A_n\}$  与  $\{B_n\}$  使得  $n$  充分大时  $\frac{1}{B_n} \sum_{i=1}^n \xi_i - A_n$  逐渐趋于  $N(0,1)$ ，则称  $\{\xi_n\}$  满足中心极限定理。

(3) (Lindeberg-Levy) 设  $\{\xi_n\}$  是彼此独立且同分布的随机变量序列，它们具有相同的期望  $\mu$  与方差  $\sigma^2$ ，则  $\lim_{n \rightarrow \infty} P\left(\frac{1}{\sqrt{n}\sigma} \sum_{i=1}^n (\xi_i - \mu) \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$ 。

(4) 中心极限定理说明，很多概率分布的标准化形式  $\frac{1}{\sqrt{D\xi}} \sum_{i=1}^n (\xi_i - E\xi)$  的最终归宿都是标准正态分布。数理统计中将重点研究正态分布和与之相关的分布。

## 第二章 数理统计概论

### 一、抽样分布的基本理论

## 1、数理统计基本概念

(1) 总体：研究对象的全体。（相当于奖池）

(2) 个体：总体中的每个元素（相当于奖池中的每张奖券）

(3) 抽样：随机抽出总体中的某些个体。（抽奖）

(4) 样本：抽样得到的若干个体所组成的集合。（抽到的奖券）其元素个数称为样本容量。

(5) 观察值：也叫样本值，是具体观察到的样本的值。

(6) 统计量：不含未知参数的关于样本的函数。代入样本观察值之后得到的函数值称为统计量的观察值。

\*常见的统计量：均值  $\bar{X}$ （有时也记为  $\bar{X}_n$ ） $= \frac{1}{n} \sum_{i=1}^n X_i$ ；方差  $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ；

样本均方差（标准差） $S_n = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ ； $k$  阶原点矩  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ； $k$  阶

中心矩  $M_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ ；顺序统计量  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ （把  $X_1, X_2, \dots, X_n$  从小到大排列生成的数组）

☆☆☆在数理统计中的方差，如果没有特殊规定，都是以  $n-1$  为分母；概率论中随机变量的方差  $D\xi$  如果写成平均数的形式，是以  $n$  为分母。前者的理由将在后面给出。

## 2、数理统计中的三个重要分布（重点在于定义！）

(1)  $\chi^2$  分布

①定义：若  $\{X_1, X_2, \dots, X_n\}$  相互独立且均服从标准正态分布  $N(0,1)$ ，则称  $\chi^2 = \sum_{i=1}^n X_i^2$  服从  $n$  个自由度的  $\chi^2$  分布，记为  $\chi^2(n)$ 。

②密度函数（不要求掌握）：
$$\varphi(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n-1}{2}} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

其中  $\Gamma(s) = \int_0^{+\infty} x^{s-1} e^{-x} dx$ . ( $s > 0$ )

③  $E\chi^2 = n$ ,  $D\chi^2 = 2n$ .

④常用数值： $\chi^2$  分布的上侧  $\alpha$  分位数  $\chi_\alpha^2(n)$ ，满足  $P(\chi^2 \geq \chi_\alpha^2(n)) = \alpha$ .

(2)  $t$  分布

①定义：若随机变量  $X$  与  $Y$  相互独立， $X \sim N(0,1)$ ， $Y \sim \chi^2(n)$ ，则称  $T = \frac{X}{\sqrt{Y/n}}$  服从  $n$  个自由度的  $t$  分布，记为  $t(n)$ 。

②密度函数（不要求掌握）：
$$\varphi(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}.$$

③  $n \geq 2$  时，存在  $ET = 0$ ； $n \geq 3$  时，存在  $DT = \frac{n}{n-2}$ 。

④常用数值：t 分布的上侧 $\alpha$ 分位数 $t_{\alpha}(n)$ ，满足 $P(T \geq t_{\alpha}(n)) = \alpha$ 。

性质： $t_{1-\alpha}(n) = -t_{\alpha}(n)$ 。

(3) F 分布

①若随机变量 $X$ 与 $Y$ 相互独立， $X \sim \chi^2(n_1)$ ， $Y \sim \chi^2(n_2)$ ，则称 $F = \frac{X/n_1}{Y/n_2}$ 服从第一个自由度为 $n_1$ ，第二个自由度为 $n_2$ 的F分布，记为 $F(n_1, n_2)$ 。

②密度函数（不要求掌握）：
$$\varphi(x) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} n_1^{\frac{n_1}{2}} n_2^{\frac{n_2}{2}} \frac{x^{\frac{n_1}{2}-1}}{(n_1x+n_2)^{\frac{n_1+n_2}{2}}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

③ $n \geq 3$ 时，存在 $EF = \frac{n}{n-2}$ ； $n \geq 5$ 时，存在 $DF = \frac{2n_2^2}{n_1(n_2-2)^2(n_2-4)}$ 。

④常用数值：F分布的上侧 $\alpha$ 分位数 $F_{\alpha}(n_1, n_2)$ ，满足 $P(F \geq F_{\alpha}(n_1, n_2)) = \alpha$ 。

性质： $F_{\alpha}(n_1, n_2) = \frac{1}{F_{1-\alpha}(n_2, n_1)}$ 。

☆形式上简记几种分布的关系：

$$\chi^2(n) = \sum_{i=1}^n [N(0,1)]^2, \quad t(n) = \frac{N(0,1)}{\sqrt{\chi^2(n)/n}}, \quad F(n_1, n_2) = \frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2}.$$

在记忆这些关系时，需明确两个问题：每一种分布由什么分布生成？生成的表达式是怎样的？

在推导一个量满足什么分布时，一般不会通过分布函数来证明（不要求掌握，并且十分麻烦），而是要努力配凑三个分布定义式的形式。

3、正态分布统计量满足的分布（不要把这些结论用在其他分布）

(1) 总体： $X \sim N(\mu, \sigma^2)$ ； $\frac{X-\mu}{\sigma} \sim N(0,1)$ 。

(2) 均值： $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ ； $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0,1)$ 。

(3) 方差 $S^2$ 与均值独立，且 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。

(4)  $\frac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)$ 。

(5) 若还有一个独立的正态分布量 $Y$ ，满足 $X \sim N(\mu_1, \sigma_1^2)$ ， $Y \sim N(\mu_2, \sigma_2^2)$ ，则有
$$\frac{\bar{X}-\bar{Y}-(\mu_1-\mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1+n_2-2), \quad \frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F(n_1-1, n_2-1).$$

其中 $S_w = \sqrt{\frac{(n_1-1)S_X^2 + (n_2-1)S_Y^2}{n_1+n_2-2}}$ 。（方差的加权平均）

二、参数估计

1、参数估计的目的：在有数据但是未知分布中的参数（如正态分布的 $\mu, \sigma^2$ ）时，需要通过统计数据估计参数的值。

2、参数估计的方法：得到一些样本观察值，用含有这些观察值及相关的统计量（如均值，方差，矩）的代数式来表示参数。

例如，在正态分布中，如果数据量够大，可认为样本均值近似为期望，样本方差

$\frac{n-1}{n}S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ （此为旧的形式）近似为方差 $\sigma^2$ 。于是有估计值：

$$\begin{cases} \hat{\mu} = \bar{X}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{n-1}{n} S^2. \end{cases}$$

3、点估计（用一些数据点进行的参数估计）

$$(1) \text{ 矩估计法：设待求参数有 } k \text{ 个，为 } \theta_1, \theta_2, \dots, \theta_k; \text{ 利用原点矩 } \begin{cases} EX \approx \bar{X} \\ EX^2 \approx \overline{X^2} \\ \dots \\ EX^k \approx \overline{X^k} \end{cases}, \text{ 解}$$

出这些参数的估计值。

(2) 极大似然估计法：取得  $n$  个样本  $X_i = x_i (1 \leq i \leq n)$  后，认为这种取值取得的概率是可能的极大值，即  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$  关于各个参数应取极大值。

①形象例子：若 A 箱中有 99 个白球、1 个黑球，B 箱中有 1 个白球、99 个黑球。在不知道哪个是 A、哪个是 B 的情况下，任取一个箱子，随机取球，取出的是白球，这时倾向于认为这个箱子像是 A，即“似然”。也即：我们倾向于认为样本的概率分布是使得  $X_i = x_i (1 \leq i \leq n)$  发生概率达到极大值的情况，如果该概率分布没有尽其所能做到“极大”，那么更可能发生的应是其他的事件。

②离散变量的最大似然估计：最大似然函数  $L(\theta_1, \dots, \theta_k) = P(X_1 = x_1) \dots P(X_n = x_n)$ 。

它应当取极值，所以  $\frac{\partial L}{\partial \theta_j} = 0. (1 \leq j \leq k)$ （在这里不讨论条件极值，一般来说这

些参数都是独立的）

③连续变量的最大似然估计： $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$  对连续变量而言趋于 0，没有意义，因此用极限来代替： $\lim_{\varepsilon \rightarrow 0^+} P(|X_1 - x_1| \leq \varepsilon, \dots, |X_n - x_n| \leq \varepsilon)$  为极大。也就是这些变量落在长度相同的微小区间内的概率应该取得极大值，因此对应的概率密度应为最大值。对应的最大似然函数为：

$$\begin{aligned} L(\theta_1, \dots, \theta_k) &= \lim_{\varepsilon \rightarrow 0^+} \frac{P(|X_1 - x_1| \leq \varepsilon, \dots, |X_n - x_n| \leq \varepsilon)}{V(|X_1 - x_1| \leq \varepsilon, \dots, |X_n - x_n| \leq \varepsilon)} = \lim_{\varepsilon \rightarrow 0^+} \frac{\prod_{i=1}^n \int_{x_i - \varepsilon}^{x_i + \varepsilon} \varphi(t) dt}{(2\varepsilon)^n} \\ &= \lim_{\varepsilon \rightarrow 0^+} \prod_{i=1}^n \frac{\varphi(\xi_i) \cdot 2\varepsilon}{2\varepsilon} = \varphi(x_1) \dots \varphi(x_n); \text{ 其中, } \xi_i \in (x_i - \varepsilon, x_i + \varepsilon). \end{aligned}$$

这里运用了积分中值定理。然后， $\frac{\partial L}{\partial \theta_j} = 0. (1 \leq j \leq k)$

(3) 点估计的效果评价

①无偏性：若  $E\hat{\theta} = \theta$ ，则称  $\hat{\theta}$  是无偏的，否则称其为有偏。（不负期望）



②有效性： $D\hat{\theta}$  越小，则称  $\hat{\theta}$  越有效。

③一致性：若对任意  $\varepsilon > 0$ ， $\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| < \varepsilon) = 1$ ，则称  $\hat{\theta}$  是  $\theta$  的一致估计。

④为什么方差分母是  $n-1$ ：

方差的旧定义是  $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 。将它直接当做正态分布  $\sigma^2$  的估计值，则

$$\begin{aligned} E\hat{\sigma}^2 &= E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n} E\left[\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right] \\ &= \frac{1}{n} E[n\bar{X}^2 - 2n\bar{X} \cdot \bar{X} + n\bar{X}^2] = E\bar{X}^2 - E(\bar{X}^2) = E(X^2) - E(\bar{X}^2) \\ &= DX + (EX)^2 - D\bar{X} - (E\bar{X})^2 = DX - D\bar{X} = \left(1 - \frac{1}{n}\right)\sigma^2 \neq \sigma^2. \end{aligned}$$

也就是说，旧的方差定义使得  $\sigma^2$  的估计值有偏离。从推导看，这偏离来自于  $D\bar{X}$ ，

也即平均值也是有波动的。所以，修改方差定义， $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ，将它

作为  $\sigma^2$  的估计值，则  $E\hat{\sigma}^2 = \sigma^2$ 。鉴于正态分布较为常用，对一般的统计数据的方差也都使用新的定义。

#### 4、区间估计

(1) 基本思想：考察参数落在哪个区间中的概率比较大。

(2) 置信区间：若  $P(\theta_1 < \theta < \theta_2) = 1 - \alpha$ ，则称  $(\theta_1, \theta_2)$  是  $\theta$  的置信度为  $1 - \alpha$  的置信区间。

(3) ☆正态分布的区间估计（其中  $u$  指标准正态分布  $N(0,1)$ ；截图来自朱胜林老师概率统计课件，此课件完整版不外传）

待估计参数	已知	使用分布公式	区间
$\mu$	$\sigma^2$	$U = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}$	$ U  < u_{\alpha/2}$
$\mu$		$T = \frac{(\bar{X} - \mu)\sqrt{n}}{S} \sim t(n-1)$	$ T  < t_{\alpha/2}(n-1)$
$\sigma^2$	$\mu$	$\chi = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$	$\chi_{1-\alpha/2}^2(n) < \chi < \chi_{\alpha/2}^2(n)$
$\sigma^2$		$\chi = \frac{n-1}{\sigma^2} S^2 \sim \chi^2(n-1)$	$\chi_{1-\alpha/2}^2(n-1) < \chi < \chi_{\alpha/2}^2(n-1)$
$\mu_1 - \mu_2$	$\sigma_1^2, \sigma_2^2$	$U = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$	$ U  < u_{\alpha/2}$
$\mu_1 - \mu_2$		$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$	$ T  < t_{\alpha/2}(n_1 + n_2 - 2)$
$\sigma_1^2/\sigma_2^2$		$F = \frac{\frac{\sigma_1^2}{S_X^2}}{\frac{\sigma_2^2}{S_Y^2}} \sim F(n_1 - 1, n_2 - 2)$	$F_{1-\alpha/2}(n_1 - 1, n_2 - 2) < F < F_{\alpha/2}(n_1 - 1, n_2 - 2)$

（最后一行： $n_2-2$  均改为  $n_2-1$ ）

#### 三、假设检验

1、假设检验是区间估计的逆过程，主要是在对参数进行了假设之后看样本所处的区间是否可以接受。

2、假设检验的基本概念

(1) 零假设  $H_0$ ：对参数的初始假设，可以是等式或不等式。

(2) 备假设  $H_1$ ：与  $H_0$  对立的假设。

(3) 弃真错误:  $H_0$  正确, 但是检验认为  $H_0$  错误。

(4) 取伪错误:  $H_0$  错误, 但是检验认为  $H_0$  正确。

(5) 双边检验:  $H_0: \theta = \theta_0$  vs  $H_1: \theta \neq \theta_0$ 。

(6) 左边检验:  $H_0: \theta = \theta_0$  vs  $H_1: \theta < \theta_0$ 。 ( $H_0$  也可以是  $\theta \geq \theta_0$ )

(7) 右边检验:  $H_0: \theta = \theta_0$  vs  $H_1: \theta > \theta_0$ 。 ( $H_0$  也可以是  $\theta \leq \theta_0$ )

3、假设检验的基本思想: 确定  $H_0$  之后, 选择一个关于样本均值的置信区间 (在这里称为接受域, 其补集称为拒绝域)。在置信度较大的情况下, 若有数据落入拒绝域, 说明小概率的事件发生了, 此时一般拒绝假设  $H_0$ ; 反之, 则接受  $H_0$ 。

4、☆正态分布的假设检验 (截图来自朱胜林老师概率统计课件, 此课件完整版不外传)

名称	$H_0$	公式	拒绝域	说明
单一样本 $u$ -检验	$\mu = \mu_0$	$u = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$	$ u  > u_{\alpha/2}$	$n > 30, \sigma$ 已知
双样本 $u$ -检验	$\mu_1 = \mu_2$	$u = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$ u  > u_{\alpha/2}$	$\sigma_1, \sigma_2$ 已知
单一样本 $t$ -检验	$\mu = \mu_0$	$t_{(n-1)} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$ t_{(n-1)}  > t_{\alpha/2}$	$n > 30, \sigma$ 未知
双样本 $t$ -检验	$\mu_1 = \mu_2$	$t_{(n_1+n_2-2)} = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ 其中: $s_w^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$	$ t_{(n_1+n_2-2)}  > t_{\alpha/2}$	$n_1 + n_2 > 40$ 且 $\sigma_1 = \sigma_2$ 未知
双样本方差的 $F$ -检验	$\sigma_1^2 = \sigma_2^2$	$F_{(n_1-1, n_2-1)} = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2}$	$F_{(n_1-1, n_2-1)} > F_{\alpha/2}$ 或 $F_{(n_1-1, n_2-1)} < F_{1-\alpha/2}$	
方差的 $\chi^2$ -检验	$\sigma^2 = \sigma_0^2$	$\chi_{(n-1)}^2 = (n-1) \frac{s^2}{\sigma_0^2}$	$\chi_{(n-1)}^2 > \chi_{\alpha/2}^2$ 或 $\chi_{(n-1)}^2 < \chi_{1-\alpha/2}^2$	
单一样本 $u$ -检验	$\mu \leq \mu_0$	$u = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$	$u > u_{\alpha}$	$n > 30, \sigma$ 已知

其他的单边检验可如上一条相似得到, 不一一列举。

5、总体分布的假设检验: 如果连分布类型也不知道, 则需要根据数据选择合适的模型进行拟合, 拟合结果有待假设检验。

在此只介绍总体分布的  $\chi^2$  拟合检验法。

(1) 总体分布函数  $F(x)$  未知。初始假设为  $H_0: F(x) = F_0(x)$ 。

(2) 若  $F_0(x)$  不带任何参数, 取实数  $-\infty = t_0 < t_1 < t_2 < \dots < t_{k-1} < t_k = +\infty$ , 记区间  $A_i = (t_{i-1}, t_i]$ ; 设  $n$  个样本观察值中落在  $A_i$  内的个数为  $n_i$ ,  $p_i = F_0(t_i) - F_0(t_{i-1})$ 。如果假设正确, 则概率与频率应接近, 即  $\left| p_i - \frac{n_i}{n} \right|$  很小。令  $\chi^2 = \sum_{i=1}^k \frac{n}{p_i} \left( p_i - \frac{n_i}{n} \right)^2$ ; 假设

正确的充要条件是  $\chi^2 \sim \chi^2(k-1)$ , 拒绝域为  $\chi^2 > \chi_{\alpha}^2(k-1)$ 。

(3) 若  $F_0(x)$  带有  $r$  个参数, 将它们全部用最大似然估计值代入, 然后按照上述步骤进行。假设正确的充要条件是  $\chi^2 \sim \chi^2(k-r-1)$ , 拒绝域为  $\chi^2 > \chi_{\alpha}^2(k-r-1)$ 。

[参考资料]

[1]复旦大学数学科学学院朱胜林老师《线性代数与概率统计》课程

[2]金路, 童裕孙, 於崇华, 张万国. 高等数学 (第四版, 下册). 高等教育出版社, 第 11-12 章

[3]茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程 (第二版). 高等教育出版社